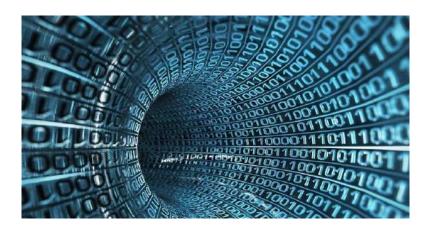
Sistemi Informativi Evoluti e Big Data



Map-Reduce – Deployment del codice

Università degli Studi di Brescia Dipartimento di Ingegneria dell'Informazione



Un esempio in pratica: WordCount

```
map(String docid, String text):
   for each word w in text:
       emit (w, 1);

reduce(String term, counts[]):
   int sum = 0;
   for each c in counts:
       sum += c;
   emit (term, sum);
```



Implementazione: librerie

```
import org.apache.hadoop.conf.Configuration;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.LongWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Job;
import org.apache.hadoop.mapreduce.Mapper;
import org.apache.hadoop.mapreduce.Reducer;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
```



Implementazione: map

Map(String docid, String text):

for each word w in text: Emit(w, 1);

```
public static class WordCountMapper
           extends Mapper<LongWritable, Text, Text, IntWritable> {
                                                                    Implementazioni
      private final static IntWritable ONE = new IntWritable(1);
                                                                     dell'interfaccia
      private final Text parola = new Text();
                                                                     Writable (Text,
     public void map(LongWritable chiave, Text testo,
                                                                    LongWritable,
                     Context contesto) throws IOException,
                                                                     FloatWritable,
                     InterruptedException {
                                                                     BooleanWritable.
        String linea = testo.toString();
                                                                     IntWritable,
        StringTokenizer tokenizer = new StringTokenizer(linea);
                                                                     ByteWritable,
        while (tokenizer.hasMoreTokens()) {
                                                                    ArrayWritable,
           parola.set(tokenizer.nextToken());
                                                                     etc.)
           contesto.write(parola, ONE);
```



Implementazione: reduce

```
public static class WordCountReducer extends Reducer<Text,
IntWritable, Text, IntWritable> {
      private IntWritable risultato = new IntWritable();
      public void reduce(Text chiave,
                     Iterable<IntWritable> valori,
                     Context contesto) throws IOException,
                     InterruptedException {
         int somma = 0;
         for(IntWritable val : valori) {
            somma += val.get();
         risultato.set(somma);
         contesto.write(chiave, risultato);
```

```
Map(String docid, String text):
for each word w in text:
Emit(w, 1);

Reduce(String term, counts[]):
```

```
int sum = 0;
for each c in counts:
    sum += c;
Emit(term, sum);
```



Implementazione: Job

```
public class WordCount {
   public static void main(String[] args) throws Exception {
      Configuration conf = new Configuration();
      Job job = Job.getInstance(conf, "Word Counter");
      job.setJarByClass(WordCount.class);
      job.setMapperClass(WordCountMapper.class);
      job.setReducerClass(WordCountReducer.class);
      FileInputFormat.addInputPath(job, new Path(args[0]));
      FileOutputFormat.setOutputPath(job, new Path(args[1]));
      job.setOutputKeyClass(Text.class);
      job.setOutputValueClass(IntWritable.class);
      System.exit(job.waitForCompletion(true)?0:1);
```



Hadoop – Documentazione utile

Un Wiki su Hadoop è disponibile al seguente link: https://hadoop.apache.org/docs/stable/

General

Overview Single Node Setup Cluster Setup Commands Reference

FileSystem Shell Compatibility Specification Downstream Developer's Gulde

Admin Compatibility Guide Interface Classification

Interface Classification FileSystem Specification

Common

CLI Mini Cluster
Native Libraries
Proxy User
Rack Awareness
Secure Mode
Service Level
Authorization
HTTP Authentication
Credential Provider API
Hadoop KMS
Tracing
Unix Shell Guide

HDFS

Architecture
User Guide
Commands Reference
NameNode HA With QJM
NameNode HA With NFS
Federation
ViewFs
Snapshots

Apache Hadoop 3.2.1

Apache Hadoop 3.2.1 incorporates a number of significant enhancements over the previous major release line (hadoop-3.2).

This release is generally available (GA), meaning that it represents a point of API stability and quality that we consider production-ready.

Overview

Users are encouraged to read the full set of release notes. This page provides an overview of the major changes.

Node Attributes Support in YARN

Node Attributes helps to tag multiple labels on the nodes based on its attributes and supports placing the containers based on expression of these labels,

More details are available in the Node Attributes documentation.

Hadoop Submarine on YARN

Hadoop Submarine enables data engineers to easily develop, train and deploy deep learning models (in TensorFlow) on very same Hadoop YARN cluster where data resides.

More details are available in the Hadoop Submarine documentation.

Storage Policy Satisfier

Supports HDFS (Hadoop Distributed File System) applications to move the blocks between storage types as they set the storage policies on files/directories.

More details are available in the Storage Policy Satisfier documentation.

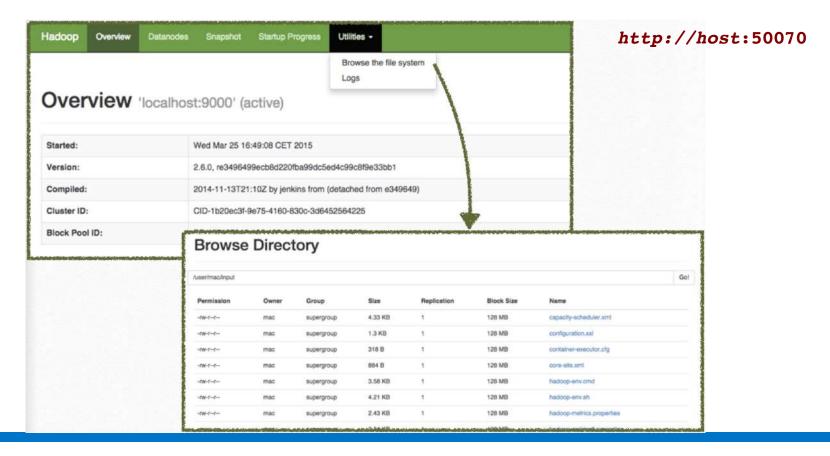


I comandi HDFS su Hadoop

```
$:~hadoop-*/bin/hdfs dfs <command> <parameters>
create a directory in hdfs
  $:~hadoop-*/bin/hdfs dfs -mkdir input
copy a local file in hdfs
  $:~hadoop-*/bin/hdfs dfs -put /tmp/example.txt input
copy result files from hdfs to local file system
  $:~hadoop-*/bin/hdfs dfs -get output/result localoutput
delete a directory in hdfs
 $:~hadoop-*/bin/hdfs dfs -rm -r input
```



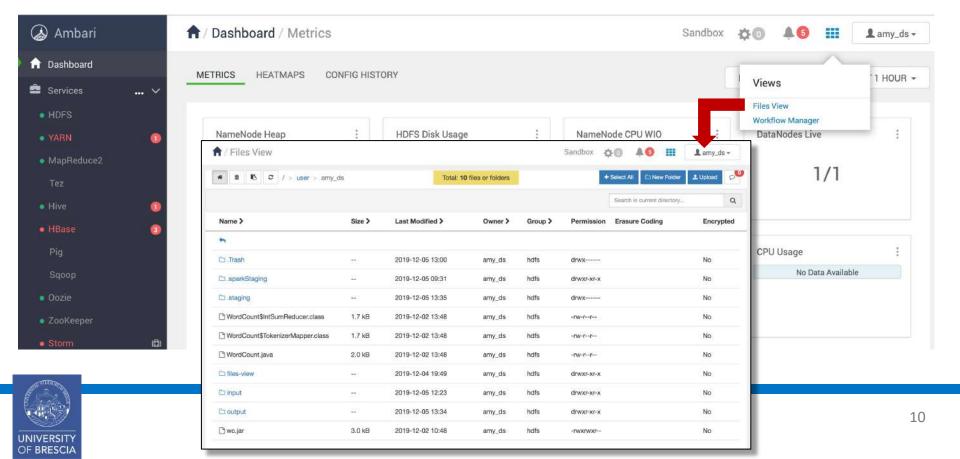
Navigare nel file system distribuito





Navigare nel file system distribuito (Ambari)

http://host:8080



Compilare un'applicazione MapReduce

Come progetto MAVEN attraverso l'IDE NetBeans (dalla versione 6.9 in poi):

```
WordCount

V □ Pacchetti dei sorgenti

V □ WordCount

WordCount.java

WordCountReducer.java

WordCountReducer.java

Pacchetti test

Dependencies

Test Dependencies

Junit-3.8.1.jar

Java Dependencies

Project Files

pom.xml
```

```
<?xml version="1.0" encoding="UTF-8"?>
<modelVersion>4.0.0</modelVersion>
   <groupId>com.mycompany
   <artifactId>WordCount</artifactId>
   <version>1.0</version>
   <packaging>jar</packaging>
   <dependencies>
      <dependency>
      <dependency>
         <groupId>org.apache.hadoop</groupId>
         <artifactId>hadoop-core</artifactId>
         <version>1.2.0
      </dependency>
      <dependency>
         <groupId>log4j</groupId>
         <artifactId>log4j</artifactId>
         <version>1.2.16
      </dependency>
   </dependencies>
   cproperties>
      <maven.compiler.source>1.8</maven.compiler.source>
      <maven.compiler.target>1.8</maven.compiler.target>
   </properties>
</project>
```



Esempio: WordCount

- 1. Generazione del file *jar* contenente le classi *Mapper*, *Reducer* e *Job* (per esempio, compilando il progetto MAVEN in NetBeans)
- 2. Spostamento del file jar sulla distribuzione Hadoop (file system locale)
- 3. Creazione delle cartelle che conterranno gli input e il risultato dell'elaborazione
- 4. Esecuzione dell'elaborazione parallela del codice
- 5. Visualizzazione dei risultati



Esempio: WordCount

- 1. Generazione del file *jar* contenente le classi *Mapper*, *Reducer* e *Job* (per esempio, compilando il progetto MAVEN in NetBeans)
- 2. Spostamento del file *jar* sulla distribuzione Hadoop (file system locale)

scp -P 2222 <files-to-transfer> <hadoop_user>@<host>:/<destination-on-server>



Esempio: WordCount

- 1. Generazione del file *jar* contenente le classi *Mapper*, *Reducer* e *Job* (per esempio, compilando il progetto MAVEN in NetBeans)
- 2. Spostamento del file jar sulla distribuzione Hadoop (file system locale)
- 3. Creazione delle cartelle che conterranno gli input e il risultato dell'elaborazione (da prompt dei comandi)

```
hdfs dfs -mkdir input
hdfs dfs -put divina_commedia.txt input
hdfs dfs -mkdir output
```



Esempio: WordCount

- 1. Generazione del file *jar* contenente le classi *Mapper*, *Reducer* e *Job* (per esempio, compilando il progetto MAVEN in NetBeans)
- 2. Spostamento del file jar sulla distribuzione Hadoop (file system locale)
- 3. Creazione delle cartelle che conterranno gli input e il risultato dell'elaborazione (tramite Ambari)





Esempio: WordCount

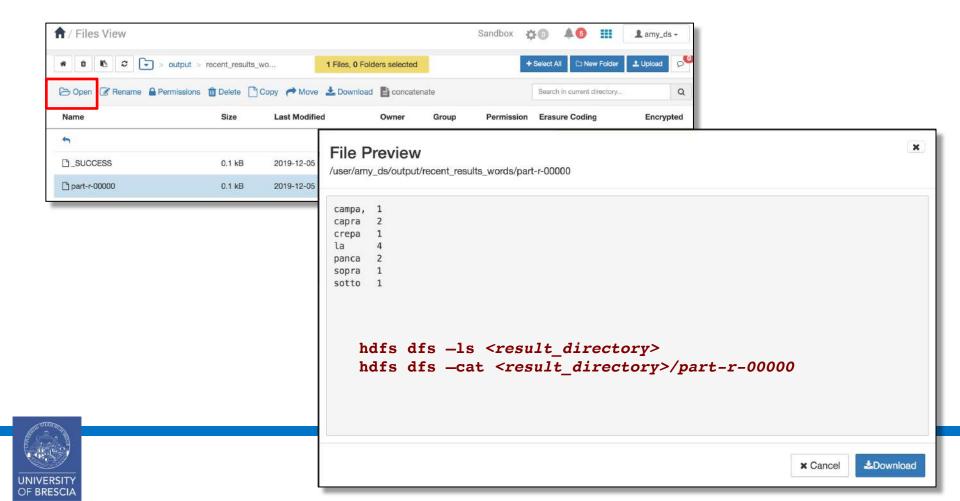
- 1. Generazione del file *jar* contenente le classi *Mapper*, *Reducer* e *Job* (per esempio, compilando il progetto MAVEN in NetBeans)
- 2. Spostamento del file jar sulla distribuzione Hadoop (file system locale)
- 3. Creazione delle cartelle che conterranno gli input e il risultato dell'elaborazione
- 4. Esecuzione dell'elaborazione parallela del codice

```
$:~hadoop-*/bin/hadoop jar <path-jar> <jar-MainClass> <jar-parameters>
```

hadoop jar <nome-file-jar> wordcount/WordCount <input> <output>



WordCount: visualizzazione dei risultati



WordCount: utilizzo di un Combiner

Nella configurazione del *Job*:

```
job.setMapperClass(WordCountMapper.class);
job.setCombinerClass(WordCountReducer.class);
job.setReducerClass(WordCountReducer.class);
```



Testare un'applicazione MapReduce

- Librerie in Python che permettono il deployment e l'esecuzione in locale di un programma Map-Reduce
- Utili per testare programmi in assenza di un cluster o in attesa di fare il caricamento su un cluster
- Esempi di librerie (Pythor): mrjob, pymr

```
python code.py
    input_file > output_file
```

```
from mrjob.job import MRJob
import re
WORD RE = re.compile(r''[\w']+")
class MRWordFregCount(MRJob):
   def mapper(self, , line):
        for word in WORD RE.findall(line):
           vield (word.lower(), 1)
   def combiner(self, word, counts):
       yield (word, sum(counts))
   def reducer(self, word, counts):
       yield (word, sum(counts))
if name == ' main ':
   MRWordFreqCount.run()
```

